

Tomasz Derek

**Wprowadzenie do sztucznej inteligencji
i uczenia maszynowego**

*Wykład dla członków
Koła Matematyki Stosowanej*

Toruń 2019

Spis treści

1	Sztuczna inteligencja	5
1.1	Czym jest sztuczna inteligencja?	5
1.2	Co to znaczy, że coś jest inteligentne?	5
1.3	Rys historyczny	5
1.3.1	Test Turinga	5
1.3.2	Problem chińskiego pokoju	5
1.3.3	Mądry Hans	5
1.4	Systemy ekspertowe	5
2	Wprowadzenie do Pythona	5
2.1	Wady i zalety języka	5
2.2	Instalacja interpretera	5
2.3	Zmienne	5
2.4	Operacje arytmetyczne	6
2.5	Instrukcje warunkowe	6
2.6	Pętle	6
2.7	Funkcje	6
2.8	Klasy	6
2.9	Dziedziczenie	6
2.10	Wprowadzenie do biblioteki Numpy	6
2.11	Wykresy z bibliotekami Matplotlib i Seaborn	6
2.12	Obsługa biblioteki Pandas	6
2.12.1	Wczytywanie danych z pliku	6
2.12.2	Tworzenie obiektu DataFrame	6
3	Uczenie maszynowe - wprowadzenie	6
3.1	Rodzaje uczenia maszynowego	6
3.1.1	Uczenie nadzorowane	6
3.1.2	Uczenie nienadzorowane	6
3.1.3	Uczenie przez wzmacnianie	6
3.2	Przykładowe zastosowania	6
3.3	Podsumowanie	6
4	Modele liniowe	6
4.1	Regresja liniowa	6
4.1.1	Prosty model regresji liniowej	7
4.1.2	Współczynnik korelacji rang Spearmana	7
4.1.3	Punkty wysokiej dźwigni	7
4.1.4	Przykład 2-wymiarowy	7
4.1.5	Przykład n-wymiarowy	7
4.1.6	Błąd	7
4.1.7	Spadek gradientu	7
4.1.8	Ocena modelu	7
4.1.9	Współczynnik determinacji	7
4.1.10	Współczynnik indeterminacji	7
4.2	Perceptron	7
4.2.1	Neuron biologiczny	7
4.2.2	Neuron McCullocha-Pittsa	7
4.2.3	Model perceptronu	7

4.2.4	Perceptron z biasem	7
4.2.5	Reguła uczenia perceptronu	8
4.2.6	Prosty algorytm uczenia perceptronu	8
4.2.7	Algorytm uczenia z kieszonką	9
4.2.8	Algorytm uczenia z zapadką	9
4.3	Maszyna liniowa	9
4.4	Adaline - adaptacyjny neuron liniowy	9
4.5	SVM - maszyna wektorów nośnych	9
5	Drzewa decyzyjne	9
5.1	Boosting	9
6	Sieci Neuronowe	9
6.1	Wprowadzenie do głębokiej sieci neuronowych	9
6.1.1	Graf obliczeniowy	9
6.2	Propagacja w przód	9
6.3	Uczenie za pomocą algorytmu wstecznej propagacji błędów	9
6.4	Implementacja wielowarstwowego perceptronu	9
7	Przetwarzanie języka naturalnego	9
8	Biblioteka Scikit - learn	9
9	Biblioteki uczenia głębokiego	9
9.1	Keras	9
9.2	Tensorflow	9
9.3	PyTorch	9
10	Przetwarzanie języka naturalnego	9
10.1	Topic modelling	9
11 A.	Notacja matematyczna	9
12 B.	Algebra liniowa	9
12.1	Wektory i operacje wektorowe	9
12.2	Macierze i ich własności	9
13 C.	Analiza matematyczna	9
13.1	Rachunek różniczkowy	9
13.1.1	Pochodne	9
13.1.2	Ekstrema lokalne	9
13.2	Rachunek całkowy	9
14 D.	Prawdopodobieństwo	9
14.1	Prawdopodobieństwo klasyczne	9
15 E.	Teoria języków formalnych	9
15.1	Wyrażenia regularne	9
16 F.	Statystyka	9

17 G. Pozostałe algorytmy	9
17.1 Algorytmy genetyczne	9
17.2 Algorytmy ewolucyjne	9

1 Sztuczna inteligencja

1.1 Czym jest sztuczna inteligencja?

Przez wielu sztuczna inteligencja kojarzona jest z świadomymi robotami, które przejmą kontrolę nad światem, a z ludzi uczynią swoich niewolników. Jednak czy do tego dojdzie

1.2 Co to znaczy, że coś jest inteligentne?

Co to znaczy, że ktoś jest inteligentny?

1.3 Rys historyczny

Rys

1.3.1 Test Turinga

Rok 1950 znany angielski matematyk Alan Turing ukazuje światu swoją wizję testu na inteligencje maszyn.

1.3.2 Problem chińskiego pokoju

Jednym z

1.3.3 Mądry Hans

Jak historia pokazuje z problematyką chińskiego pokoju mogliśmy się spotkać w ... roku

1.4 Systemy ekspertowe

2 Wprowadzenie do Pythona

W tym rozdziale omówimy

2.1 Wady i zalety języka

Jak każdy język programowania tak i Python ma swoje wady i zalety.

2.2 Instalacja interpretera

2.3 Zmienne

Ala ma kota

- 2.4 Operacje arytmetyczne
- 2.5 Instrukcje warunkowe
- 2.6 Pętle
- 2.7 Funkcje
- 2.8 Klasy
- 2.9 Dziedziczenie
- 2.10 Wprowadzenie do biblioteki Numpy
- 2.11 Wykresy z bibliotekami Matplotlib i Seaborn
- 2.12 Obsługa biblioteki Pandas
 - 2.12.1 Wczytywanie danych z pliku
 - 2.12.2 Tworzenie obiektu DataFrame

3 Uczenie maszynowe - wprowadzenie

3.1 Rodzaje uczenia maszynowego

3.1.1 Uczenie nadzorowane

Definicja. Regresja jest to dowolna metoda statystyczna pozwalająca estymować warunkową wartość zmiennej objaśnianej dla zmiennych objaśniających.

Mówiąc prościej regresją nazywamy pewną funkcję zależności wartości jednej zmiennej (zmiennych) od drugiej.

3.1.2 Uczenie nienadzorowane

3.1.3 Uczenie przez wzmacnianie

3.2 Przykładowe zastosowania

3.3 Podsumowanie

4 Modele liniowe

4.1 Regresja liniowa

Definicja. Regresję liniową nazywamy metodę szacowania zmiennej objaśnianej \mathbf{Y} (zwanej również zmienną zależną lub warunkową wartością oczekiwaną zmiennej \mathbf{Y}) przy znanych wartościach $\mathbf{X}_0, \mathbf{X}_1, \dots, \mathbf{X}_n$ (zwanymi zmiennymi objaśniającymi, niezależnymi lub predyktorami) przy założeniu, że zależność pomiędzy \mathbf{Y} a $\mathbf{X}_1, \dots, \mathbf{X}_n$ jest określona funkcją liniową.

Mieszkanie	Powierzchnia w <i>metrach</i> ²	Cena w tys
Mieszkanie1	60	117
Mieszkanie2	30	60
Mieszkanie3	90	170
Mieszkanie4	200	400

4.1.1 Prosty model regresji liniowej

Zapiszmy wzór na prostą regresji liniowej z jedną zmienną niezależną X .

$$y = \beta_0 + \beta_1 x + \varepsilon$$

β_0, β_1 nazywamy współczynnikami regresji, zaś ε błędem losowym, błędem predykcji, błędem oszacowania lub też resztą.

4.1.2 Współczynnik korelacji rang Spearmana

ad

4.1.3 Punkty wysokiej dźwigni

4.1.4 Przykład 2-wymiarowy

4.1.5 Przykład n-wymiarowy

4.1.6 Błąd

4.1.7 Spadek gradientu

4.1.8 Ocena modelu

4.1.9 Współczynnik determinacji

4.1.10 Współczynnik indeterminacji

4.2 Perceptron

W tym rozdziale skupimy się na jednej z najprostszych sieci neuronowych, a mianowicie na perceptronie. W toku naszych rozważań omówimy jego możliwości, a także ograniczenia. Ponadto poznamy różne algorytmy uczenia takie jak algorytm z kieszonką oraz zapadką. Zobaczymy również w jaki sposób możemy wykorzystać **dyskretną transformatę Fouriera** oraz **radialne funkcje bazowe** w celu uzyskania lepszych wyników przez nasz algorytm.

4.2.1 Neuron biologiczny

Przez wiele lat...

4.2.2 Neuron McCullocha-Pittsa

4.2.3 Model perceptronu

4.2.4 Perceptron z biasem

Tym co odróżnia perceptron z biasem od zwykłego perceptronu to fakt, występowania pewnej dodatkowej wagi w_0 stowarzyszonej z dodatkowym wejściem x_0 , którego wartość jest stała równa $+1$. W

literaturze jednak, możemy się spotkać z zapisem zawierającym pewną wartość progową oznaczaną przez literę θ . Nie należy się jednak tym martwić, ponieważ zależność między wagą w_0 , a θ wygląda następująco:

$$\theta = -w_0$$

W efekcie tego blok sumowania naszego perceptronu możemy zapisać w następujący sposób:

$$O(x_1, \dots, x_n) = \sum_{i=1}^n x_i w_i + w_0$$

lub też

$$O(x_1, \dots, x_n) = \sum_{i=1}^n x_i w_i - \theta$$

Spójrzmy na interpretację geometryczną tego wzoru dla przypadku dwuwymiarowego wejścia. Na początku rozważmy pewien wektor wag $w = [w_1, w_2]$, pewien wektor wejściowy $x = [x_1, x_2]$ oraz θ będące naszym biasem. Korzystając ze wzoru powyżej otrzymamy następującą zależność:

$$O(x_1, x_2) = x_1 w_1 + x_2 w_2 - \theta$$

Łatwo możemy zauważyć, że jest to równanie pewnej płaszczyzny (w tym przypadku prostej) o równaniu:

$$x_1 w_1 + x_2 w_2 - \theta = 0$$

Po wyznaczeniu x_2 możemy zapisać równanie w sposób równoważny.

$$x_2 = -\frac{w_1}{w_2} x_1 + \frac{\theta}{w_2}$$

Patrząc na sam wzór możemy wywnioskować, iż wartość θ wpływa na *przesuwanie* się hiperpłaszczyzny decyzyjnej względem początku układu, w tym przypadku dwuwymiarowego układu współrzędnych kartezjańskich.

4.2.5 Reguła uczenia perceptronu

4.2.6 Prosty algorytm uczenia perceptronu

Zanim jednak opowiemy o działaniu tego algorytmu, spróbujmy intuicyjnie dość to tego co algorytm uczenia powinien robić. Przyjmijmy, że e_i będzie wylosowanym przykładem uczącym, a a_i będzie oczekiwanym wyjściem, przez o zaś oznaczmy wyjście naszego modelu dla wejścia e_i . Wtedy nasz błąd będzie określony jako $err = a_i - o$.

4.2.7 Algorytm uczenia z kieszonką

4.2.8 Algorytm uczenia z zapadką

4.3 Maszyna liniowa

4.4 Adaline - adaptacyjny neuron liniowy

4.5 SVM - maszyna wektorów nośnych

5 Drzewa decyzyjne

5.1 Boosting

6 Sieci Neuronowe

6.1 Wprowadzenie do głębokiej sieci neuronowych

6.1.1 Graf obliczeniowy

6.2 Propagacja w przód

6.3 Uczenie za pomocą algorytmu wstecznej propagacji błędów

6.4 Implementacja wielowarstwowego perceptronu

7 Przetwarzanie języka naturalnego

8 Biblioteka Scikit - learn

9 Biblioteki uczenia głębokiego

9.1 Keras

9.2 Tensorflow

9.3 PyTorch

10 Przetwarzanie języka naturalnego

10.1 Topic modelling

11 A. Notacja matematyczna

12 B. Algebra liniowa

12.1 Wektory i operacje wektorowe

12.2 Macierze i ich własności

13 C. Analiza matematyczna

13.1 Rachunek różniczkowy

13.1.1 Pochodne

13.1.2 Ekstremum lokalne