

**Tomasz Derek**

**Wprowadzenie do sztucznej inteligencji  
i uczenia maszynowego**

*Wykład dla członków  
Koła Matematyki Stosowanej*

Toruń 2019

# Spis treści

<b>1</b>	<b>Sztuczna inteligencja</b>	<b>5</b>
1.1	Czym jest sztuczna inteligencja? . . . . .	5
1.2	Co to znaczy, że coś jest inteligentne? . . . . .	5
1.3	Rys historyczny . . . . .	5
1.3.1	Test Turinga . . . . .	5
1.3.2	Problem chińskiego pokoju . . . . .	5
1.3.3	Mądry Hans . . . . .	5
1.4	Systemy ekspertowe . . . . .	5
<b>2</b>	<b>Wprowadzenie do Pythona</b>	<b>5</b>
2.1	Wady i zalety języka . . . . .	5
2.2	Instalacja interpretera . . . . .	5
2.3	Zmienne . . . . .	5
2.4	Operacje arytmetyczne . . . . .	6
2.5	Instrukcje warunkowe . . . . .	6
2.6	Pętle . . . . .	6
2.7	Funkcje . . . . .	6
2.8	Klasy . . . . .	6
2.9	Dziedziczenie . . . . .	6
2.10	Wprowadzenie do biblioteki Numpy . . . . .	6
2.11	Wykresy z bibliotekami Matplotlib i Seaborn . . . . .	6
2.12	Obsługa biblioteki Pandas . . . . .	6
2.12.1	Wczytywanie danych z pliku . . . . .	6
2.12.2	Tworzenie obiektu DataFrame . . . . .	6
<b>3</b>	<b>Uczenie maszynowe - wprowadzenie</b>	<b>6</b>
3.1	Rodzaje uczenia maszynowego . . . . .	6
3.1.1	Uczenie nadzorowane . . . . .	6
3.1.2	Uczenie nienadzorowane . . . . .	6
3.1.3	Uczenie przez wzmacnianie . . . . .	6
3.2	Przykładowe zastosowania . . . . .	6
3.3	Podsumowanie . . . . .	6
<b>4</b>	<b>Modele liniowe</b>	<b>6</b>
4.1	Regresja liniowa . . . . .	6
4.1.1	Prosty model regresji liniowej . . . . .	7
4.1.2	Współczynnik korelacji rang Spearmana . . . . .	7
4.1.3	Punkty wysokiej dźwigni . . . . .	7
4.1.4	Przykład 2-wymiarowy . . . . .	7
4.1.5	Przykład n-wymiarowy . . . . .	7
4.1.6	Błąd . . . . .	7
4.1.7	Spadek gradientu . . . . .	7
4.1.8	Ocena modelu . . . . .	7
4.1.9	Współczynnik determinacji . . . . .	7
4.1.10	Współczynnik indeterminacji . . . . .	7
4.2	Perceptron . . . . .	7
4.2.1	Neuron biologiczny . . . . .	7
4.2.2	Neuron McCullocha-Pittsa . . . . .	7
4.2.3	Model perceptronu . . . . .	7

4.2.4	Perceptron z biasem . . . . .	7
4.2.5	Reguła uczenia perceptronu . . . . .	9
4.2.6	Prosty algorytm uczenia perceptronu . . . . .	9
4.2.7	Algorytm uczenia z kieszonką . . . . .	9
4.2.8	Algorytm uczenia z zapadką . . . . .	9
4.3	Maszyna liniowa . . . . .	9
4.4	Adaline - adaptacyjny neuron liniowy . . . . .	9
4.5	SVM - maszyna wektorów nośnych . . . . .	9
<b>5</b>	<b>Drzewa decyzyjne</b>	<b>9</b>
5.1	Boosting . . . . .	9
<b>6</b>	<b>Sieci Neuronowe</b>	<b>9</b>
6.1	Wprowadzenie do głębokiej sieci neuronowych . . . . .	9
6.1.1	Graf obliczeniowy . . . . .	9
6.2	Propagacja w przód . . . . .	9
6.3	Uczenie za pomocą algorytmu wstecznej propagacji błędów . . . . .	9
6.4	Implementacja wielowarstwowego perceptronu . . . . .	9
<b>7</b>	<b>Przetwarzanie języka naturalnego</b>	<b>9</b>
<b>8</b>	<b>Biblioteka Scikit - learn</b>	<b>9</b>
<b>9</b>	<b>Biblioteki uczenia głębokiego</b>	<b>9</b>
9.1	Keras . . . . .	9
9.2	Tensorflow . . . . .	9
9.3	PyTorch . . . . .	9
<b>10</b>	<b>Przetwarzanie języka naturalnego</b>	<b>9</b>
10.1	Topic modelling . . . . .	9
<b>11 A.</b>	<b>Notacja matematyczna</b>	<b>9</b>
<b>12 B.</b>	<b>Algebra liniowa</b>	<b>9</b>
12.1	Wektory i operacje wektorowe . . . . .	9
12.2	Macierze i ich własności . . . . .	9
<b>13 C.</b>	<b>Analiza matematyczna</b>	<b>9</b>
13.1	Rachunek różniczkowy . . . . .	9
13.1.1	Pochodne . . . . .	9
13.1.2	Ekstrema lokalne . . . . .	9
13.2	Rachunek całkowy . . . . .	9
<b>14 D.</b>	<b>Prawdopodobieństwo</b>	<b>9</b>
14.1	Prawdopodobieństwo klasyczne . . . . .	9
<b>15 E.</b>	<b>Teoria języków formalnych</b>	<b>9</b>
15.1	Wyrażenia regularne . . . . .	9
<b>16 F.</b>	<b>Statystyka</b>	<b>9</b>

<b>17 G. Pozostałe algorytmy</b>	<b>9</b>
17.1 Algorytmy genetyczne . . . . .	9
17.2 Algorytmy ewolucyjne . . . . .	9

# 1 Sztuczna inteligencja

## 1.1 Czym jest sztuczna inteligencja?

Przez wielu sztuczna inteligencja kojarzona jest z świadomymi robotami, które przejmą kontrolę nad światem, a z ludzi uczynią swoich niewolników. Jednak czy do tego dojdzie

## 1.2 Co to znaczy, że coś jest inteligentne?

Co to znaczy, że ktoś jest inteligentny?

## 1.3 Rys historyczny

Rys

### 1.3.1 Test Turinga

W 1950 angielski matematyk Alan Turing zaproponował test, który miał określić czy dany program jest inteligentny.

### 1.3.2 Problem chińskiego pokoju

Jednym z

### 1.3.3 Mądry Hans

Jak historia pokazuje z problematyką chińskiego pokoju mogliśmy się spotkać w ... roku

## 1.4 Systemy ekspertowe

# 2 Wprowadzenie do Pythona

W tym rozdziale omówimy

## 2.1 Wady i zalety języka

Jak każdy język programowania tak i Python ma swoje wady i zalety.

## 2.2 Instalacja interpretera

## 2.3 Zmienne

Ala ma kota

- 2.4 Operacje arytmetyczne
- 2.5 Instrukcje warunkowe
- 2.6 Pętle
- 2.7 Funkcje
- 2.8 Klasy
- 2.9 Dziedziczenie
- 2.10 Wprowadzenie do biblioteki Numpy
- 2.11 Wykresy z bibliotekami Matplotlib i Seaborn
- 2.12 Obsługa biblioteki Pandas
  - 2.12.1 Wczytywanie danych z pliku
  - 2.12.2 Tworzenie obiektu DataFrame

## 3 Uczenie maszynowe - wprowadzenie

### 3.1 Rodzaje uczenia maszynowego

#### 3.1.1 Uczenie nadzorowane

*Definicja.* Regresja jest to dowolna metoda statystyczna pozwalająca estymować warunkową wartość zmiennej objaśnianej dla zmiennych objaśniających.

Mówiąc prościej regresją nazywamy pewną funkcję zależności wartości jednej zmiennej (zmiennych) od drugiej.

#### 3.1.2 Uczenie nienadzorowane

#### 3.1.3 Uczenie przez wzmacnianie

### 3.2 Przykładowe zastosowania

### 3.3 Podsumowanie

## 4 Modele liniowe

### 4.1 Regresja liniowa

*Definicja.* Regresją liniową nazywamy metodę szacowania zmiennej objaśnianej  $\mathbf{Y}$  (zwanej również zmienną zależną lub warunkową wartością oczekiwaną zmiennej  $\mathbf{Y}$ ) przy znanych wartościach  $\mathbf{X}_0, \mathbf{X}_1, \dots, \mathbf{X}_n$  (zwanymi zmiennymi objaśniającymi, niezależnymi lub predyktorami) przy założeniu, że zależność pomiędzy  $\mathbf{Y}$  a  $\mathbf{X}_1, \dots, \mathbf{X}_n$  jest określona funkcją liniową.

Mieszkanie	Powierzchnia w <i>metrach</i> <sup>2</sup>	Cena w tys
Mieszkanie1	60	117
Mieszkanie2	30	60
Mieszkanie3	90	170
Mieszkanie4	200	400

#### 4.1.1 Prosty model regresji liniowej

Zapiszmy wzór na prostą regresji liniowej z jedną zmienną niezależną  $X$ .

$$y = \beta_0 + \beta_1 x + \varepsilon$$

$\beta_0, \beta_1$  nazywamy współczynnikami regresji, zaś  $\varepsilon$  błędem losowym, błędem predykcji, błędem oszacowania lub też resztą.

#### 4.1.2 Współczynnik korelacji rang Spearmana

ad

#### 4.1.3 Punkty wysokiej dźwigni

#### 4.1.4 Przykład 2-wymiarowy

#### 4.1.5 Przykład n-wymiarowy

#### 4.1.6 Błąd

#### 4.1.7 Spadek gradientu

#### 4.1.8 Ocena modelu

#### 4.1.9 Współczynnik determinacji

#### 4.1.10 Współczynnik indeterminacji

### 4.2 Perceptron

W tym rozdziale skupimy się na jednej z najprostszych sieci neuronowych, a mianowicie na perceptronie. W toku naszych rozważań omówimy jego możliwości, a także ograniczenia. Ponadto poznamy różne algorytmy uczenia takie jak algorytm z kieszonką oraz zapadką. Zobaczymy również w jaki sposób możemy wykorzystać **dyskretną transformatę Fouriera** oraz **radialne funkcje bazowe** w celu uzyskania lepszych wyników przez nasz algorytm.

#### 4.2.1 Neuron biologiczny

Przez wiele lat...

#### 4.2.2 Neuron McCullocha-Pittsa

#### 4.2.3 Model perceptronu

#### 4.2.4 Perceptron z biasem

Tym co odróżnia perceptron z biasem od tego to fakt, występowania dodatkowej wagi  $w_0$  stowarzyszonej z pewnym wejściem  $x_0$ , którego wartość jest stała równa +1. W literaturze jednak, możemy się

spotkać z zapisem zawierającym pewną wartość progową oznaczaną przez literę  $\theta$ . Nie należy się jednak tym martwić, ponieważ zależność między wagą  $w_0$ , a  $\theta$  wygląda następująco:

$$\theta = -w_0$$

W efekcie tego blok sumowania naszego perceptronu możemy zapisać w następujący sposób:

$$O(x_1, \dots, x_n) = \sum_{i=1}^n x_i w_i + w_0$$

lub też

$$O(x_1, \dots, x_n) = \sum_{i=1}^n x_i w_i - \theta$$

Spójrzmy na interpretację geometryczną tego wzoru dla przypadku dwuwymiarowego wejścia. Na początku rozważmy pewien wektor wag  $w = [w_1, w_2]$ , pewien wektor wejściowy  $x = [x_1, x_2]$  oraz  $\theta$  będące naszym biasem. Korzystając ze wzoru powyżej otrzymamy następującą zależność:

$$O(x_1, x_2) = x_1 w_1 + x_2 w_2 - \theta$$

Łatwo możemy zauważyć, że jest to równanie pewnej płaszczyzny (w tym przypadku prostej) o równaniu:

$$x_1 w_1 + x_2 w_2 - \theta = 0$$

Po wyznaczeniu  $x_2$  możemy zapisać równanie w sposób równoważny.

$$x_2 = -\frac{w_1}{w_2} x_1 + \frac{\theta}{w_2}$$

Patrząc na sam wzór możemy wywnioskować, iż wartość  $\theta$  wpływa na *przesuwanie* się płaszczyzny względem początku układu, w tym przykładzie dwuwymiarowego układu współrzędnych kartezjańskich.



4.2.5 Reguła uczenia perceptronu

4.2.6 Prosty algorytm uczenia perceptronu

4.2.7 Algorytm uczenia z kieszonką

4.2.8 Algorytm uczenia z zapadką

4.3 Maszyna liniowa

4.4 Adaline - adaptacyjny neuron liniowy

4.5 SVM - maszyna wektorów nośnych

## 5 Drzewa decyzyjne

5.1 Boosting

## 6 Sieci Neuronowe

6.1 Wprowadzenie do głębokiej sieci neuronowych

6.1.1 Graf obliczeniowy

6.2 Propagacja w przód

6.3 Uczenie za pomocą algorytmu wstecznej propagacji błędów

6.4 Implementacja wielowarstwowego perceptronu

## 7 Przetwarzanie języka naturalnego

## 8 Biblioteka Scikit - learn

## 9 Biblioteki uczenia głębokiego

9.1 Keras

9.2 Tensorflow

9.3 PyTorch

## 10 Przetwarzanie języka naturalnego

10.1 Topic modelling

## 11 A. Notacja matematyczna

## 12 B. Algebra liniowa

12.1 Wektory i operacje wektorowe

12.2 Macierze i ich własności

## 13 C. Analiza matematyczna 9

13.1 Rachunek różniczkowy