

**Tomasz Derek**

**Wprowadzenie do sztucznej inteligencji  
i uczenia maszynowego**

*Wykład dla członków  
Koła Matematyki Stosowanej*

Toruń 2019

# Spis treści

|          |   |          |
|----------|---|----------|
| <b>1</b> | <b>Sztuczna inteligencja</b>                          | <b>5</b> |
| 1.1      | Czym jest sztuczna inteligencja? . . . . .            | 5        |
| 1.2      | Co to znaczy, że coś jest inteligentne? . . . . .     | 5        |
| 1.3      | Rys historyczny . . . . .                             | 5        |
| 1.3.1    | Test Turinga . . . . .                                | 5        |
| 1.3.2    | Problem chińskiego pokoju . . . . .                   | 5        |
| 1.3.3    | Mądry Hans . . . . .                                  | 5        |
| 1.4      | Systemy ekspertowe . . . . .                          | 5        |
| <b>2</b> | <b>Wprowadzenie do Pythona</b>                        | <b>5</b> |
| 2.1      | Wady i zalety języka . . . . .                        | 5        |
| 2.2      | Instalacja interpretera . . . . .                     | 5        |
| 2.3      | Zmienne . . . . .                                     | 5        |
| 2.4      | Operacje arytmetyczne . . . . .                       | 6        |
| 2.5      | Instrukcje warunkowe . . . . .                        | 6        |
| 2.6      | Pętle . . . . .                                       | 6        |
| 2.7      | Funkcje . . . . .                                     | 6        |
| 2.8      | Klasy . . . . .                                       | 6        |
| 2.9      | Dziedziczenie . . . . .                               | 6        |
| 2.10     | Wprowadzenie do biblioteki Numpy . . . . .            | 6        |
| 2.11     | Wykresy z bibliotekami Matplotlib i Seaborn . . . . . | 6        |
| 2.12     | Obsługa biblioteki Pandas . . . . .                   | 6        |
| 2.12.1   | Wczytywanie danych z pliku . . . . .                  | 6        |
| 2.12.2   | Tworzenie obiektu DataFrame . . . . .                 | 6        |
| <b>3</b> | <b>Uczenie maszynowe - wprowadzenie</b>               | <b>6</b> |
| 3.1      | Rodzaje uczenia maszynowego . . . . .                 | 6        |
| 3.1.1    | Uczenie nadzorowane . . . . .                         | 6        |
| 3.1.2    | Uczenie nienadzorowane . . . . .                      | 6        |
| 3.1.3    | Uczenie przez wzmacnianie . . . . .                   | 6        |
| 3.2      | Przykładowe zastosowania . . . . .                    | 6        |
| 3.3      | Podsumowanie . . . . .                                | 6        |
| <b>4</b> | <b>Modele liniowe</b>                                 | <b>6</b> |
| 4.1      | Regresja liniowa . . . . .                            | 6        |
| 4.1.1    | Prosty model regresji liniowej . . . . .              | 7        |
| 4.1.2    | Współczynnik korelacji rang Spearmana . . . . .       | 7        |
| 4.1.3    | Punkty wysokiej dźwigni . . . . .                     | 7        |
| 4.1.4    | Przykład 2-wymiarowy . . . . .                        | 7        |
| 4.1.5    | Przykład n-wymiarowy . . . . .                        | 7        |
| 4.1.6    | Błąd . . . . .  | 7        |
| 4.1.7    | Spadek gradientu . . . . .                            | 7        |
| 4.1.8    | Ocena modelu . . . . .                                | 7        |
| 4.1.9    | Współczynnik determinacji . . . . .                   | 7        |
| 4.1.10   | Współczynnik indeterminacji . . . . .                 | 7        |
| 4.2      | Perceptron . . . . .                                  | 7        |
| 4.2.1    | Neuron biologiczny . . . . .                          | 7        |
| 4.2.2    | Neuron McCullocha-Pittsa . . . . .                    | 7        |
| 4.2.3    | Model perceptronu . . . . .                           | 7        |

|           |   |           |
|-----------|---|-----------|
| 4.2.4     | Perceptron z biasem . . . . .                                     | 7         |
| 4.2.5     | Reguła uczenia perceptronu . . . . .                              | 8         |
| 4.2.6     | Prosty algorytm uczenia perceptronu . . . . .                     | 8         |
| 4.2.7     | Algorytm uczenia z kieszonką . . . . .                            | 9         |
| 4.2.8     | Algorytm uczenia z zapadką . . . . .                              | 9         |
| 4.3       | Maszyna liniowa . . . . .   | 9         |
| 4.4       | Adaline - adaptacyjny neuron liniowy . . . . .                    | 9         |
| 4.5       | SVM - maszyna wektorów nośnych . . . . .                          | 9         |
| <b>5</b>  | <b>Drzewa decyzyjne</b>   | <b>9</b>  |
| 5.1       | Boosting . . . . .  | 9         |
| <b>6</b>  | <b>Sieci Neuronowe</b>  | <b>9</b>  |
| 6.1       | Wprowadzenie do głębokiej sieci neuronowych . . . . .             | 9         |
| 6.1.1     | Graf obliczeniowy . . . . .                                       | 9         |
| 6.2       | Propagacja w przód . . . . .                                      | 9         |
| 6.3       | Uczenie za pomocą algorytmu wstecznej propagacji błędów . . . . . | 9         |
| 6.4       | Implementacja wielowarstwowego perceptronu . . . . .              | 9         |
| <b>7</b>  | <b>Przetwarzanie języka naturalnego</b>                           | <b>9</b>  |
| <b>8</b>  | <b>Biblioteka Scikit - learn</b>                                  | <b>9</b>  |
| <b>9</b>  | <b>Biblioteki uczenia głębokiego</b>                              | <b>9</b>  |
| 9.1       | Keras . . . . .   | 9         |
| 9.1.1     | Przykład prostego MLP . . . . .                                   | 9         |
| 9.2       | Tensorflow . . . . .  | 10        |
| 9.3       | PyTorch . . . . .   | 10        |
| <b>10</b> | <b>Przetwarzanie języka naturalnego</b>                           | <b>10</b> |
| 10.1      | Topic modelling . . . . .   | 10        |
| <b>11</b> | <b>A. Notacja matematyczna</b>                                    | <b>10</b> |
| <b>12</b> | <b>B. Algebra liniowa</b>   | <b>10</b> |
| 12.1      | Wektory i operacje wektorowe . . . . .                            | 10        |
| 12.2      | Macierze i ich własności . . . . .                                | 10        |
| <b>13</b> | <b>C. Analiza matematyczna</b>                                    | <b>10</b> |
| 13.1      | Rachunek różniczkowy . . . . .                                    | 10        |
| 13.1.1    | Pochodne . . . . .  | 10        |
| 13.1.2    | Ekstrema lokalne . . . . .  | 10        |
| 13.2      | Rachunek całkowy . . . . .  | 10        |
| <b>14</b> | <b>D. Prawdopodobieństwo</b>                                      | <b>10</b> |
| 14.1      | Prawdopodobieństwo klasyczne . . . . .                            | 10        |
| <b>15</b> | <b>E. Teoria języków formalnych</b>                               | <b>10</b> |
| 15.1      | Wyrażenia regularne . . . . .                                     | 10        |
| <b>16</b> | <b>F. Statystyka</b>  | <b>10</b> |

|                                     |           |
|-------------------------------------|-----------|
| <b>17 G. Pozostałe algorytmy</b>    | <b>10</b> |
| 17.1 Algorytmy genetyczne . . . . . | 10        |
| 17.2 Algorytmy ewolucyjne . . . . . | 10        |

# 1 Sztuczna inteligencja

## 1.1 Czym jest sztuczna inteligencja?

Przez wielu sztuczna inteligencja kojarzona jest z świadomymi robotami, które przejmą kontrolę nad światem, a z ludzi uczynią swoich niewolników. Jednak czy do tego dojdzie

## 1.2 Co to znaczy, że coś jest inteligentne?

Co to znaczy, że ktoś jest inteligentny?

## 1.3 Rys historyczny

Rys

### 1.3.1 Test Turinga

Rok 1950 znany angielski matematyk Alan Turing ukazuje światu swoją wizję testu na inteligencje maszyn.

### 1.3.2 Problem chińskiego pokoju

Jednym z

### 1.3.3 Mądry Hans

Jak historia pokazuje z problematyką chińskiego pokoju mogliśmy się spotkać w ... roku

## 1.4 Systemy ekspertowe

# 2 Wprowadzenie do Pythona

W tym rozdziale omówimy

## 2.1 Wady i zalety języka

Jak każdy język programowania tak i Python ma swoje wady i zalety.

## 2.2 Instalacja interpretera

## 2.3 Zmienne

Ala ma kota

- 2.4 Operacje arytmetyczne
- 2.5 Instrukcje warunkowe
- 2.6 Pętle
- 2.7 Funkcje
- 2.8 Klasy
- 2.9 Dziedziczenie
- 2.10 Wprowadzenie do biblioteki Numpy
- 2.11 Wykresy z bibliotekami Matplotlib i Seaborn
- 2.12 Obsługa biblioteki Pandas
  - 2.12.1 Wczytywanie danych z pliku
  - 2.12.2 Tworzenie obiektu DataFrame

## 3 Uczenie maszynowe - wprowadzenie

### 3.1 Rodzaje uczenia maszynowego

#### 3.1.1 Uczenie nadzorowane

*Definicja.* Regresja jest to dowolna metoda statystyczna pozwalająca estymować warunkową wartość zmiennej objaśnianej dla zmiennych objaśniających.

Mówiąc prościej regresją nazywamy pewną funkcję zależności wartości jednej zmiennej (zmiennych) od drugiej.

#### 3.1.2 Uczenie nienadzorowane

#### 3.1.3 Uczenie przez wzmacnianie

### 3.2 Przykładowe zastosowania

### 3.3 Podsumowanie

## 4 Modele liniowe

### 4.1 Regresja liniowa

*Definicja.* Regresją liniową nazywamy metodę szacowania zmiennej objaśnianej  $\mathbf{Y}$  (zwanej również zmienną zależną lub warunkową wartością oczekiwaną zmiennej  $\mathbf{Y}$ ) przy znanych wartościach  $\mathbf{X}_0, \mathbf{X}_1, \dots, \mathbf{X}_n$  (zwanymi zmiennymi objaśniającymi, niezależnymi lub predyktorami) przy założeniu, że zależność pomiędzy  $\mathbf{Y}$  a  $\mathbf{X}_1, \dots, \mathbf{X}_n$  jest określona funkcją liniową.

| Mieszkanie  | Powierzchnia<br>w <i>metrach</i> <sup>2</sup> | Cena<br>w tys |
|-------------|---|---------------|
| Mieszkanie1 | 60  | 117           |
| Mieszkanie2 | 30  | 60            |
| Mieszkanie3 | 90  | 170           |
| Mieszkanie4 | 200   | 400           |

#### 4.1.1 Prosty model regresji liniowej

Zapiszmy wzór na prostą regresji liniowej z jedną zmienną niezależną  $\mathbf{X}$ .

$$y = \beta_0 + \beta_1 x + \varepsilon$$

$\beta_0, \beta_1$  nazywamy współczynnikami regresji, zaś  $\varepsilon$  błędem losowym, błędem predykcji, błędem oszacowania lub też resztą.

#### 4.1.2 Współczynnik korelacji rang Spearmana

ad

#### 4.1.3 Punkty wysokiej dźwigni

#### 4.1.4 Przykład 2-wymiarowy

#### 4.1.5 Przykład n-wymiarowy

#### 4.1.6 Błąd

#### 4.1.7 Spadek gradientu

#### 4.1.8 Ocena modelu

#### 4.1.9 Współczynnik determinacji

#### 4.1.10 Współczynnik indeterminacji

### 4.2 Perceptron

W tym rozdziale skupimy się na jednej z najprostszych sieci neuronowych, a mianowicie na perceptronie. W toku naszych rozważań omówimy jego możliwości, a także ograniczenia. Ponadto poznamy różne algorytmy uczenia takie jak algorytm z kieszonką oraz zapadką. Zobaczymy również w jaki sposób możemy wykorzystać **dyskretną transformatę Fouriera** oraz **radialne funkcje bazowe** w celu uzyskania lepszych wyników przez nasz algorytm.

#### 4.2.1 Neuron biologiczny

Przez wiele lat...

#### 4.2.2 Neuron McCullocha-Pittsa

#### 4.2.3 Model perceptronu

#### 4.2.4 Perceptron z biasem

Tym co odróżnia perceptron z biasem od zwykłego perceptronu to fakt, występowania pewnej dodatkowej wagi  $w_0$  stowarzyszonej z dodatkowym wejściem  $x_0$ , którego wartość jest stała równa  $+1$ . W

literaturze jednak, możemy się spotkać z zapisem zawierającym pewną wartość progową oznaczaną przez literę  $\theta$ . Nie należy się jednak tym martwić, ponieważ zależność między wagą  $w_0$ , a  $\theta$  wygląda następująco:

$$\theta = -w_0$$

W efekcie tego blok sumowania naszego perceptronu możemy zapisać w następujący sposób:

$$O(x_1, \dots, x_n) = \sum_{i=1}^n x_i w_i + w_0$$

lub też

$$O(x_1, \dots, x_n) = \sum_{i=1}^n x_i w_i - \theta$$

Spójrzmy na interpretację geometryczną tego wzoru dla przypadku dwuwymiarowego wejścia. Na początku rozważmy pewien wektor wag  $w = [w_1, w_2]$ , pewien wektor wejściowy  $x = [x_1, x_2]$  oraz  $\theta$  będące naszym biasem. Korzystając ze wzoru powyżej otrzymamy następującą zależność:

$$O(x_1, x_2) = x_1 w_1 + x_2 w_2 - \theta$$

Łatwo możemy zauważyć, że jest to równanie pewnej płaszczyzny (w tym przypadku prostej) o równaniu:

$$x_1 w_1 + x_2 w_2 - \theta = 0$$

Po wyznaczeniu  $x_2$  możemy zapisać równanie w sposób równoważny.

$$x_2 = -\frac{w_1}{w_2} x_1 + \frac{\theta}{w_2}$$

Patrząc na sam wzór możemy wywnioskować, iż wartość  $\theta$  wpływa na *przesuwanie* się hiperpłaszczyzny decyzyjnej względem początku układu, w tym przypadku dwuwymiarowego układu współrzędnych kartezjańskich.

#### 4.2.5 Reguła uczenia perceptronu

#### 4.2.6 Prosty algorytm uczenia perceptronu

Zanim jednak opowiemy o działaniu tego algorytmu, spróbujmy intuicyjnie dość to tego co algorytm uczenia powinien robić. Przyjmijmy, że  $e_i$  będzie wylosowanym przykładem uczącym, a  $a_i$  będzie oczekiwanym wyjściem, przez  $o$  zaś oznaczmy wyjście naszego modelu dla wejścia  $e_i$ . Wtedy nasz błąd będzie określony jako  $err = a_i - o$ .



4.2.7 Algorytm uczenia z kieszonką

4.2.8 Algorytm uczenia z zapadką

4.3 Maszyna liniowa

4.4 Adaline - adaptacyjny neuron liniowy

4.5 SVM - maszyna wektorów nośnych

## 5 Drzewa decyzyjne

5.1 Boosting

## 6 Sieci Neuronowe

6.1 Wprowadzenie do głębokiej sieci neuronowych

6.1.1 Graf obliczeniowy

6.2 Propagacja w przód

6.3 Uczenie za pomocą algorytmu wstecznej propagacji błędów

6.4 Implementacja wielowarstwowego perceptronu

## 7 Przetwarzanie języka naturalnego

## 8 Biblioteka Scikit - learn

## 9 Biblioteki uczenia głębokiego

9.1 Keras

9.1.1 Przykład prostego MLP

Zanim przejdziemy do pisania naszej sieci najpierw zaimportujemy potrzebne moduły. Pierwszym z nich będzie moduł *keras*

```
[1]: import keras
```

Aby poprawić czytelności i skrócić kod zaimportujemy z modułu *keras*, a dokładniej z *keras.models* model o nazwie *Sequential* oraz z *keras.layers* warstwę *Dense*

```
[2]: from keras.models import Sequential
```

```
[3]: from keras.layers import Dense
```

- 9.2 Tensorflow
- 9.3 PyTorch
- 10 Przetwarzanie języka naturalnego
  - 10.1 Topic modelling
- 11 A. Notacja matematyczna
- 12 B. Algebra liniowa
  - 12.1 Wektory i operacje wektorowe
  - 12.2 Macierze i ich własności
- 13 C. Analiza matematyczna
  - 13.1 Rachunek różniczkowy
    - 13.1.1 Pochodne
    - 13.1.2 Ekstrema lokalne
  - 13.2 Rachunek całkowy
- 14 D. Prawdopodobieństwo
  - 14.1 Prawdopodobieństwo klasyczne
- 15 E. Teoria języków formalnych
  - 15.1 Wyrażenia regularne
- 16 F. Statystyka
- 17 G. Pozostałe algorytmy
  - 17.1 Algorytmy genetyczne
  - 17.2 Algorytmy ewolucyjne